

ÉCOLE MAROCAINE DES SCIENCES DE L'INGÉNIEUR
Filière 3IIR S2

CAHIER DES CHARGES

Projet de Fin d'Année (PFA)

SYSTÈME INTELLIGENT DE DÉTECTION DE PHISHING

par Apprentissage Automatique (FakeFinder)

Réalisé par :

**Yahya KHALIFI
Elias CHAKROUN**

Encadré par :

Mme Soukayna MAYARA

Année Universitaire : 2025-2026

Table des matières

1	Contexte et objectifs du projet	2
1.1	Contexte général	2
1.2	Problématique	2
1.3	Objectifs	2
2	Périmètre du projet	2
2.1	Inclus	2
2.2	Exclus	2
3	Acteurs et besoins utilisateurs	2
3.1	Acteurs	2
3.2	Besoins	3
4	Exigences fonctionnelles	3
5	Exigences non fonctionnelles	3
6	Environnement technique	3
7	Planning de réalisation (Du 6 Avril au 10 Mai 2026)	3
8	Bibliographie	5

1 Contexte et objectifs du projet

1.1 Contexte général

Avec l'augmentation massive des cyberattaques, les emails frauduleux (phishing) sont devenus le principal vecteur de compromission de données. Ce projet s'inscrit dans une démarche de recherche appliquée visant à sécuriser les échanges numériques.

1.2 Problématique

Comment permettre à un utilisateur novice de vérifier rapidement la légitimité d'un email suspect sans risquer de cliquer sur des liens malveillants et sans que ses données ne soient conservées par le serveur ?

1.3 Objectifs

- Fournir une interface web simple pour l'analyse des fichiers d'emails (.eml).
- Attribuer un score de risque (faible, moyen, élevé) via un modèle d'Apprentissage Automatique.
- Identifier les éléments suspects (liens masqués, anomalies d'en-tête).
- Garantir un respect absolu de la vie privée grâce à une architecture "Zero Retention".

2 Périmètre du projet

2.1 Inclus

- Interface web responsive pour le dépôt de fichiers .eml.
- Moteur d'analyse en mémoire basé sur des techniques de classification d'IA (Random Forest).
- Génération d'un rapport détaillé expliquant le score de risque.

2.2 Exclus

- Suppression automatique des emails dans la boîte de réception de l'utilisateur.
- Analyse antivirus des pièces jointes exécutables (fichiers .exe, .pdf).

3 Acteurs et besoins utilisateurs

3.1 Acteurs

- **Utilisateur (Visiteur / Connecté)** : Soumet des emails, consulte les résultats d'analyse instantanés et gère son historique personnel (si connecté).
- **Administrateur** : Supervise l'utilisation de la plateforme, gère les comptes et audite les rapports générés.

3.2 Besoins

L'utilisateur doit pouvoir obtenir un résultat d'analyse fiable et compréhensible en moins de 5 secondes après le dépôt du fichier sur la plateforme.

4 Exigences fonctionnelles

- F1. Authentification :** Accès sécurisé pour l'interface utilisateur (historique) et l'administration.
- F2. Analyse de contenu :** Extraction automatique des URL et vérification de réputation (via l'intégration prévue de l'API VirusTotal en V2).
- F3. Analyse d'en-tête :** Vérification de la cohérence de l'expéditeur et de l'intégrité du domaine.
- F4. Alertes visuelles :** Affichage d'un score de risque (0-100) accompagné d'un code couleur clair (Vert/Orange/Rouge).

5 Exigences non fonctionnelles

- **Performance :** Temps de scan de bout-en-bout inférieur à 5 secondes par email.
- **Sécurité :** Confidentialité absolue des données traitées (Zero Retention, aucun fichier stocké sur le disque dur).
- **Ergonomie :** Interface claire, minimaliste, respectant les standards UI/UX modernes avec une zone Drag-and-Drop.

6 Environnement technique

- **Backend :** Python avec le framework **Django**.
- **IA & Machine Learning :** Bibliothèques **Scikit-learn**, **Pandas** et **Joblib** pour l'entraînement et l'inférence du modèle.
- **Base de données :** **PostgreSQL** pour le stockage des rapports, des URL suspectes et de l'historique utilisateur.
- **Services Externes (Perspectives) :** API **VirusTotal** pour la Cyber Threat Intelligence (réputation des liens).

7 Planning de réalisation (Du 6 Avril au 10 Mai 2026)

Ce planning suit la démarche systématique de développement logiciel, adaptée sur un cycle agile de 5 semaines.

Période	Phase et Activités	Livrable
Du 06 au 12 Avril	Recherche documentaire, État de l'art, Conception (UML) et Maquettage.	CDC & Conception
Du 13 au 19 Avril	Développement du Backend Django et moteur de parsing email en mémoire.	API d'analyse
Du 20 au 26 Avril	Traitement de données (TF-IDF), entraînement de l'IA et développement Frontend.	Version Beta
Du 27 Avr au 03 Mai	Tests de détection sur le dataset et validation des performances.	Rapport de tests
Du 04 au 10 Mai	Rédaction du rapport final de PFA et préparation de la soutenance.	Rapport Final

TABLE 1 – Planning de réalisation du PFA (Avril - Mai 2026)

8 Bibliographie

- [1] Breiman, L. (2001). *Random forests*. Machine Learning, 45(1), 5-32.
- [2] Pedregosa, F., et al. (2011). *Scikit-learn : Machine learning in Python*. Journal of Machine Learning Research.
- [3] Mme Soukayna MAYARA. *Recherche Scientifique : Support de cours*. EMSI Casablanca : Filière 3IIR, 2025-2026.